



Informe técnico: retos, problemas y soluciones

Almería Viajes

Juan José Juárez Mensales

ÍNDICE

1. Preparación del Entorno y Librerías	2
2. Fase de Ingesta, Limpieza y Transformación (ETL)	2
3. Fase de Enriquecimiento Analítico (Deep Learning & NLP)	3
4. Capa de Persistencia y Gobierno de Datos en AWS Cloud	4
5. Interfaz de Usuario (UX) y Entrega de Productos Finales	5
6. Opciones de Expansión y Futuras Implementaciones (Roadmap de Innovación)	6

1. Preparación del Entorno y Librerías

- **Problema:** Incompatibilidad de dependencias en entornos locales y necesidad de procesamiento pesado para modelos de lenguaje masivos.
- **Solución Aplicada:** Uso de **Google Colab** como entorno de ejecución unificado en la nube. Esto garantiza que cualquier auditor ejecute el archivo .ipynb con idénticas versiones de librerías (pysentimiento, folium, pyproj, gradio) y aproveche la aceleración por hardware (**GPU**) para la inferencia de los modelos BERT.

2. Fase de Ingesta, Limpieza y Transformación (ETL)

- **Problema A (Codificación Crítica):** El dataset original usa codificación Latin-1, provocando que las tildes y eñes (fundamentales en la toponimia de Almería) se corrompan y visualicen como caracteres extraños (M&oacu;jacar).
- **Solución A:** Saneamiento forzado y reconversión de *encodings* en la carga de archivos para garantizar una codificación estandarizada en **UTF-8**, blindando la integridad del texto.
- **Problema B (Geolocalización Incompatible):** Las coordenadas del registro oficial de turismo nacional vienen proyectadas en formato de planos **UTM (EPSG:25830)**, inservibles para los motores de mapas web globales.
- **Solución B:** Implementación de un módulo matemático con la librería pyproj para reproyectar en tiempo real las coordenadas planas a coordenadas geográficas esféricas **WGS84 (EPSG:4326)**, mapeando cada establecimiento con precisión milimétrica GPS.
- **Problema C (Fuzzy Matching / Cruce de Tablas Caótico):** Cruzar los datos del catastro oficial con las opiniones web por el nombre del establecimiento fallaba masivamente debido a discrepancias ortográficas ("*Hotel Gran Fama*", "*H. Gran Fama*", "*gran fama hotel*").
- **Solución C:** Desarrollo de un algoritmo de normalización morfológica llamado `norm_name`. Mediante expresiones regulares (`re.sub`), limpia acentos, caracteres especiales, fuerza minúsculas y elimina las stop-words de categoría (*hotel*, *hostal*,

pensión, camping). Esto generó una "llave de cruce limpia" (`match_key`) logrando una fusión matricial estricta e impecable vía `pd.merge()`.

3. Fase de Enriquecimiento Analítico (Deep Learning & NLP)

- **Problema A (Sesgo e Incertidumbre en Clasificaciones Binarias):** Al evaluar la polaridad de los comentarios, los modelos tradicionales obligan a etiquetar como positivo o negativo textos que son ambiguos, falseando la métrica del negocio.
- **Solución A:** Configuración de un **Filtro de Certidumbre Matemática (Threshold)** fijado en el **60%**. Si la probabilidad arrojada por la red neuronal BERT no supera este umbral, el sistema clasifica de forma rigurosa el comentario como **"INCONCLUSO"** en lugar de especular, aumentando drásticamente la confiabilidad para los gestores del destino.
- **Problema B (Abstracción Emocional no Operativa):** Los modelos BERT de psicología emocional arrojan clasificaciones nativas complejas y en inglés (*joy, sadness, anger*), poco amigables para analistas de negocio ajenos a la programación.
- **Solución B:** Creación de una capa de traducción y mapeo semántico que homogeniza las variables al castellano y las adapta para que luzcan perfectas y corporativas en herramientas de Inteligencia de Negocio.
- **Problema C (Segmentación Demográfica Inexistente):** Las edades de los turistas eran valores numéricos dispersos, dificultando la agrupación analítica para identificar patrones por nichos de mercado.
- **Solución C:** Implementación de un proceso de discretización matemática utilizando `pd.cut()`, convirtiendo las edades en variables cualitativas ordinales bajo rangos sociológicos formales: *'Joven (<30)'*, *'Adulto (30-55)'* y *'Mayor (>55)'*.

4. Capa de Persistencia y Gobierno de Datos en AWS Cloud

- **Problema A (Corrupción de Base de Datos por Nulos):** El DataFrame enriquecido por la IA contenía filas parciales con campos de texto vacíos o coordenadas nulas. Inyectar esto directamente en producción corrompería las visualizaciones finales y los cálculos relacionales.
- **Solución A:** Implementación de políticas estrictas de **Data Cleansing corporativo**. Antes de cualquier interacción con el servidor, un filtro ultra-sólido elimina filas vacías o nulas en las dimensiones críticas de negocio (nombre_establecimiento y municipio).
- **Problema B (Escritura e Infraestructura Remota):** Persistir los datos de forma local en archivos CSV aislaba la información y requería cargas manuales propensas a errores.
- **Solución B:** Migración del almacenamiento local a una **Infraestructura Cloud**. Se configuró una conexión remota segura mediante SQLAlchemy y el conector PyMySQL a una base de datos relacional MySQL alojada en una instancia de **Amazon RDS (AWS)**, sobrescribiendo de manera controlada la tabla de producción.
- **Problema C (Falta de Confirmación del Servidor Cloud / Caja Negra):** Tras ordenar la inyección a AWS, el entorno de Colab informaba del fin del proceso, pero no existía una certeza física de que los datos hubiesen impactado correctamente en el servidor cloud.
- **Solución C:** Diseño de un **Módulo de Auditoría Remota**. Al finalizar la inyección, el script abre un canal de comunicación independiente con el servidor de AWS y ejecuta una consulta nativa SQL (SELECT COUNT(*) FROM informe_turismo), contrastando físicamente el número de filas en la nube y certificando el éxito total del despliegue.

5. Interfaz de Usuario (UX) y Entrega de Productos Finales

- **Problema A (Bloqueo de Pantalla y Caos en la Visualización):** Al intentar renderizar mapas interactivos de Folium con miles de marcadores, máscaras geoespaciales opacas y mapas de calor simultáneos dentro de Google Colab, la pestaña web colapsaba o se congelaba, impidiendo su visualización.
- **Solución A:** Rediseño completo de la entrega cartográfica mediante un enfoque de **Distribución Autónoma**. El mapa se procesa al 100% en segundo plano y se compila directamente en un archivo físico estático .html (SentiAlmeria_Mapa_Clientes.html). Se eliminó el renderizado nativo dentro de Colab, permitiendo descargar el archivo para abrirlo con un simple doble clic en cualquier navegador de forma fluida, interactiva y a pantalla completa.
- **Problema B (Necesidad de Entorno de Pruebas Técnico vs Comercial):** El cliente necesita un mapa limpio y a pantalla completa, pero el equipo de ingeniería o de control de calidad requiere probar el comportamiento de los modelos lingüísticos ante nuevos textos simulados.
- **Solución B:** Despliegue de una **Consola de Inferencia Semántica** aislada mediante la librería Gradio. De este modo, la celda de Colab se convierte exclusivamente en una interfaz de simulación y banco de pruebas de la IA, donde el usuario teclea cualquier reseña y visualiza instantáneamente las etiquetas de sentimiento, la emoción y las palabras clave extraídas por SpaCy.

6. Opciones de Expansión y Futuras Implementaciones (Roadmap de Innovación)

Con la infraestructura central de datos, los modelos NLP y el almacenamiento cloud en AWS plenamente operativos, se identifican las siguientes líneas estratégicas para expandir las capacidades del ecosistema en futuras iteraciones:

A. Arquitectura de Machine Learning en Streaming (Procesamiento Inmediato)

- **Limitación actual:** El procesamiento con los modelos Transformer BERT y el etiquetado morfológico de SpaCy se realiza mediante una lógica en lotes (*Batch Processing*).
- **Futura Implementación:** Migrar hacia un paradigma de streaming utilizando Apache Kafka o AWS Kinesis. Cada vez que un turista publique una opinión en la web, el texto se inyectará como un evento en la cola, activando el clasificador de sentimientos de la IA de forma inmediata y actualizando el servidor de AWS RDS en cuestión de milisegundos.

B. Ampliación del Filtro Demográfico mediante Inferencia de Perfiles

- **Limitación actual:** Las variables sociodemográficas como la edad o el sexo están limitadas a la disponibilidad del dataset unificado.
- **Futura Implementación:** Implementar un segundo clasificador basado en Inteligencia Artificial para el análisis del perfil del usuario (sin vulnerar la privacidad). Modelos especializados de Machine Learning podrían analizar la estructura del texto, la variedad léxica o los modismos culturales para inferir de forma estadística el país de origen exacto del turista o su grupo de comportamiento (viajero solitario, turismo familiar, viajes de negocios).

C. Despliegue de un Cuadro de Mando Ejecutivo (Business Intelligence en la Nube)

- **Limitación actual:** El entregable comercial actual es un archivo HTML independiente centrado en la perspectiva geográfica.
- **Futura Implementación:** Vincular de manera nativa la base de datos de AWS RDS con una instancia en la nube de **Power BI Service** o **AWS Quicksight**. Esto permitirá diseñar un dashboard de control corporativo donde los patronatos de turismo no solo vean el mapa, sino también gráficos de tendencias temporales, KPIs de evolución del sentimiento por mes, nubes de palabras dinámicas y alertas automatizadas cuando la reputación de un municipio caiga por debajo de un umbral crítico.

D. Arquitectura LLM y Análisis de Causa Raíz (Generative AI)

- **Limitación actual:** El sistema categoriza emociones y extrae palabras clave sueltas, pero no explica de forma narrativa el "porqué" de las malas experiencias.
- **Futura Implementación:** Integrar modelos de lenguaje grande (LLM) de código abierto como *Llama 3* o *Mistral* a través de técnicas de **RAG (Generación Aumentada por Recuperación)**. Al agrupar las reseñas negativas de un hotel específico, el LLM podría redactar automáticamente un informe ejecutivo resumido para el gerente: *"El 45% de los clientes reportan descontento debido al tiempo de espera en el desayuno y la falta de mantenimiento en el aire acondicionado de la segunda planta"*.